

# Usando icenReg dados censurados por intervalo R

## v2.0.9

Clifford Anderson Bergman

13 de janeiro de 2024

## Conteúdo

|     |                                                  |    |
|-----|--------------------------------------------------|----|
| 1   | Introdução                                       | 1  |
| 1.1 | IntervaloCensura.....                            | 1  |
| 1.2 | Estimadores Clássicos .....                      | 2  |
| 1.3 | Modelos adequados com icenReg .....              | 4  |
| 1.4 | Exemplos de dados em icenReg .....               | 4  |
| 2   | Modelos de ajuste usando icenReg                 | 5  |
| 2.1 | Modelos não paramétricos .....                   | 5  |
|     | semiparamétricos.....                            | 6  |
| 2.3 | Modelos Paramétricos.....                        | 8  |
| 2.4 | Modelos Paramétricos Bayesianos .....            | 10 |
| 2.5 | Extraindo Estimativas e ICs .....                | 15 |
| 3   | Inspecionando o modelo de ajuste                 | 16 |
| 3.1 | Examinando a distribuição da linha de base ..... | 16 |
| 3.2 | Examinando o efeito da covariância .....         | 18 |
| 4   | Apêndice                                         | 19 |
| 4.1 | Bootstrapping Paralelo .....                     | 19 |

**1 Introdução** Este manual tem como objetivo fornecer uma introdução ao uso de icenReg para analisar dados censurados por intervalo. Está escrito com a expectativa de que o leitor esteja familiarizado

com métodos básicos de análise de sobrevivência. Familiaridade com as curvas de Kaplan-Meier, modelos de regressão de sobrevivência (CoxPH, AFT e probabilidades proporcionais) e princípios bayesianos devem ser suficientes para tudo o que foi descoberto neste texto.

**1.1 Censura de intervalo** A censura de intervalo ocorre quando uma resposta é conhecida apenas até o intervalo. A

exemplo clássico de teste para doenças na clínica do médico; se os testes de assunto forem negativos  $t_1$  e positivo  $t_2$ , tudo o que é conhecido é que o sujeito adquiriu a doença em  $(t_1, t_2)$ , em vez de um tempo exato. Outros exemplos de classe incluem examinando ratos de teste para tumores após sacrifício (resultados em status atual ou caso

EU dados censurados por intervalo, nos quais todas as observações são censuradas à esquerda ou à direita, em oposição às mais gerais caso II, que permite qualquer intervalo), modelos de escolha do cliente em economia (os clientes são apresentados a preços por um período produto e escolha comprar ou não, o pesquisador quer saber a distribuição de valor máximo de gasto; isso resulta em dados de status atuais novamente), métodos de produção de dados para análises de sensores (para reduzir a carga no sistema de sensores, mensagem é intencionalmente suprimido se o resultado for uma região esperada) e o ajuste de dados (respostas relatadas apenas até o intervalo, em alguns casos, aparecem nos assuntos anônimo, em alguns casos reduz o tamanho dos dados).

Muitas vezes, a censura de intervalo é ignorada na análise. Por exemplo, a idade geralmente é relatado apenas até o ano, em vez de uma variável contínua; quando a os sujeitos relatam que sua idade é 33, a informação que temos é realmente que sua idade está no intervalo [33, 34). No caso de estes intervalos serem muito curtos em relação à questão de interesse, como no caso da idade declarada no âmbito científico a questão é sobre a idade do feto do diabetes tipo II, a tendência introduzida pela ignorância a censura de intervalo pode ser pequena ou até mesmo ignorada. No entanto, no caso em que a largura dos intervalos não seja trivial, métodos estatísticos que levem em conta para isso deve ser usado para análise confiável.

A nota padrão para censura de intervalo é que cada sujeito tem um tempo de evento real  $t_{eu}$  que é potencialmente não observado. Em vez disso, observamos uma intervenção de resposta  $e_{u_{eu}} \leq r_{eu}$  de modo que o tempo do evento real não saiba que ocorreu dentro dele. O comportamento padrão é assumir que é um intervalo semiaberto, semifechado, ou seja,  $t_{eu} \in \mathcal{TAG}_{\infty} \cap (e_{u_{eu}} \leq r_{eu}]$ .

Uma exceção à regra nesta notação é que  $(t_{eu} \leq t_{eu}]$  sempre implica que o evento  $e_{u_{eu}}$  não censurado com  $\text{time} = t_{eu}$ , apesar de ser um intervalo indefinido. Isso permite observações sem censura ( $e_{u_{eu}} = r_{eu}$ ), censurado à direita ( $r_{eu} = \mathcal{TAG}_{\infty}$ ), censurado à esquerda ( $e_{u_{eu}} = 0$ ) não há nada acima ( $0 < l_{eu} < r_{eu} < \mathcal{TAG}_{\infty}$ ).

Em `icenReg`, vários modelos estão incluídos nos quais o valor de resposta pode ser censurado por intervalo. Se quatro dados contiverem os valores L e R, representando os lados esquerdo e direito do intervalo de resposta, podemos passar nossa resposta

para um modelo de regressão usando qualquer um deles

```
cbind(L,R)
Surv(L,R,tipo="intervalo2")
```

## 1.2 Estimadores Clássicos

O tópico da censura de intervalos começou no campo da análise de sobrevivência. Embora agora é considerado em outros campos de estudo (como a regressão bit), neste caso tempo `icenReg` foca em modelos de sobrevivência.

Um dos modelos mais antigos é o Non-Parametric Maximum Likelihood Estimator (NPMLE), também conhecido como Turnbull's Estimator. Este é uma generalização das curvas de Kaplan-Meier (que é uma generalização do empírico

função de distribuição) que permite a censura de intervalo. Desacostume o Kaplan Meier curves, a solução não está incluída na forma e vários algoritmos têm foi proposto para computação eficiente.

Modelos semiparamétricos também existem na literatura; dois modelos de regressão clássicos se ajustam `icenReg` são o modelo Cox-PH e o modelo proporcional.

<sup>1</sup> Em `icenReg`, se os limites do intervalo estão incluídos ou não podem ser controlados pela opção B nas funções de `autoajuste`.

O conhecido Cox-PH, ou modelo proporcional de regressão de riscos, tem a propriedade que

$$h(t; X; \beta) = h_0(t) e^{X\beta}$$

onde  $h(t; X; \beta)$  é a condição de taxa de risco para as covariáveis  $X$  e parâmetros de regressão  $\beta$ , com  $h_0$  como a função de risco de linha de base. Essa relação é equivalente a

$$S(t; X; \beta) = S_0(t) e^{-X\beta}$$

onde  $S(t; X; \beta)$  é a sobrevivência condicional e  $S_0(t)$  é a sobrevivência básica função.

O modelo de probabilidades proporcionais um tanto menos comum pode ser expresso como

$$\text{Probabilidades}(S(t; X; \beta)) = e^{-\beta} \text{Probabilidades}(S(t))$$

ou

$$\frac{\text{RTAG}_{\infty}(S(t; X; \beta))}{X\beta} = e^{-\beta} \frac{\text{RTAG}_{\infty}(S(t))}{S(t)}$$

Ao contrário do exemplo especial do modelo CoxPH com dados censurados à direita, é muito difícil estimar os parâmetros de regressão sem estimar a distribuição da linha de base.<sup>2</sup> O modelo pode ser mantido semiparamétrico (ou seja, não há necessidade de decidir sobre uma distribuição de linha de base paramétrica) usando o Turnbull estimador, modificado para levar em conta o modelo de regressão fornecido, como a linha de base distribuição. O modelo semiparamétrico pode se tornar computacionalmente muito difícil, pois o número de parâmetros de linha de base pode ser bastante alto (até  $n$ ), que deve seguir restrições de forma (ou seja, um conjunto de massas de probabilidade ou cumulativas função de risco, que deve aumentar estritamente) e não há forma fechada solução para parâmetros de regressão ou de linha de base. Uma das contribuições são os algoritmos em *icenReg* tornar o campo da computação estatística eficiente em termos de estimadores não paramétricos e semiparamétricos, permitindo estimativas relativamente eficientes em computadores padrão (ou seja, menos que um segundo) amostras relativamente grandes ( $n = 10.000$  para o modelo semiparamétrico,  $n = 100.000$  para o modelo não paramétrico), embora os modelos semiparamétricos ainda são modelos significativamente mais lentos que totalmente paramétricos.

Modelos totalmente paramétricos são bem calculados usando de forma justa algoritmos padrão. Além dos riscos proporcionais e modelos de probabilidades, o modelo de tempo de falha acelerado pode ser usado para modelagem paramétrica. Estes os modelos têm a seguinte relação:

$$S(t; X; \beta) = S_0(\text{para } X\beta)$$

Por razões técnicas não discutidas aqui, este modelo é muito simples de implementar para um modelo totalmente paramétrico, mas muito difícil para um modelo semi-paramétrico. Como tal, *icenReg* contém bancos para um modelo de falha de tempo acelerado paramétrico completo, mas não um modelo paramétrico.

Há pequenas complicações no fato de que a censura de intervalo pode ser o registro função de verossimilhança para não côncava. No entanto, para dados dimensionados razoáveis, a

<sup>2</sup> <TAG1> foram propostos, mas com grande custo computacional sem nenhum benefício estatístico claro.

a função de logverossimilhança geralmente é localmente côncava ao modo e apenas leve modificações são necessárias para abordar esta questão. Na prática, totalmente paramétrico os modelos devem ser usados com cautela; a falta de valores observados significa isso a inspeção do modelo pode ser difícil; há reistohistogramas, etc., a serem feitos. Como tais modelos, mesmo que paramétricos, são usados para a análise final fortemente encorajado a usar modelos semi-paramétricos pelo menos para inspeção de modelos. icenReg tempo de falha acelerado totalmente paramétrico, odds proporcionais e modelos de risco proporcionais para dados censurados por intervalo.

### 1.3 Modelos ajustados com registro

Neste momento, o seguinte conjunto de modelos pode ser adequado (nome na função de análise chamada icenReg):

- NPMLE( ic\_np )
- Modelo semiparamétrico( ic\_sp )
  - modelo tipo de modelo
    - \* "po" para probabilidades proporcionais
    - \* "ph" por riscos proporcionais
- Modelo totalmente paramétrico mais frequente( ic\_par ) ou modelo bayesiano( ic\_bayes )
  - modelo tipo de modelo
    - \* "po" para probabilidades proporcionais
    - \* "ph" por riscos proporcionais
    - \* "ré" para modelo de tempo de falha acelerado
  - dist distribuição forbaselineada
    - \* "exponencial"
    - \* "gama"
    - \* "weibull"
    - \* "lnorm"
    - \* "loglogístico"
    - \* "generalgamma"

Além disso, icenReg inclui várias ferramentas de diagnóstico. Estas incluem

- Gráficos para diagnóstico da distribuição da linha de base( diag\_linha de base )
- Gráficos para diagnóstico de efeitos covariáveis( diag\_covar )

### 1.4 Registros de exemplos de dados

O pacote inclui 3 fontes de dados exemplificados: uma função que simula dados e dois conjuntos de dados amostrados. A função de simulação é simIC\_weib , que simulates interval censored regression data with a Weibull baseline distribution. Os conjuntos de dados amostrados são Dados de ratos , que contém tumores de estado atual de controle de dois grupos de ratos e IR\_diabetes , que inclui dados sobre o tempo de diabetes, nefropatia diabética, em que 136 de 731 observações

são censurados por intervalo após acompanhamento desnecessário.

## 2 Modelos de ajuste usando icenReg

### 2.1 Modelos não paramétricos

O estimador de máxima verossimilhança não paramétrico (NPMLE) pode ser usado

ic\_np . Se o conjunto de dados for relativamente pequeno e o usuário estiver interessado em testes não paramétricos, como a estatística de classificação de log, na verdade aconselhamos o uso do

intervalo pacote, pois fornece várias funções de teste. No entanto, com- colocando o NPMLE icenReg é várias vezes mais rápido que intervalo, soiflarge conjuntos de dados são usados (ou seja,  $> 1.000$ ), o usuário pode ter uma boca para usar icenReg para se adequar ao NPMLE. E embora o teste de hipóteses não esteja atualmente disponível para o NPMLE em icenReg, esses ajustes ainda podem fornecer diagnósticos visuais para modelos semiparamétricos e totalmente paramétricos.

Para ajustar um modelo NPMLE para dados censurados por intervalo, consideraremos o Dados de ratos fornecido icenReg. Este conjunto de dados contém três variáveis: eu, você e grp. eu e você representam o vídeo à esquerda e à direita do intervalo que contém o tempo do evento (nota: dataiscurrentstatus) e grp é um indicador de grupo com duas categorias.

```
>dados(miceData)
>cabeça(miceData,3)
```

```
l ugrp
10381ce
20477ce
30485ce
```

Podemos instalar um estimador não paramétrico para cada grupo por


```
>np_fit=ic_np(cbind(l,u)~grp,data=miceData)
```

Se quiséssemos apenas um lefit para ambos os grupos, isso poderia ser feito de duas maneiras. Os dois ajustes são equivalentes, mas são usados apenas para demonstração, se possível sintaxe.

```
>groupedFit1<-ic_np(cbind(l,u)~0,data=miceData)
>groupedFit2<-ic_np(miceData[,c('l','u')])
```

Os ajustes podem ser plotados da seguinte forma:

```
>plot(np_fit,col=c('azul','laranja'),
+ xlab='Tempo',ylab='Sobrevivência Estimada')
```



Olhando para os gráficos, podemos ver um recurso único sobre o NPMLE para dados censurados por intervalo. Isso, há duas linhas usadas para apresentar a curva de sobrevivência. Isso ocorre porque com dados censurados por intervalo, o NPMLE nem sempre é único; qualquer curva que esteja entre as duas linhas tem a mesma probabilidade. Para por exemplo, qualquer curva que esteja entre as duas linhas do blues maximiza a probabilidade associada a "ge" grupo de ratos.

## 2.2 Modelos semiparamétricos

Modelos semiparamétricos podem ser ajustados com `ic_sp` função. Esta função segue a sintaxe de regressão padrão. Por exemplo, nós nos encaixaremos `IR_diabetes` conjunto de dados, que contém dados sobre o tempo de nefropatia diabética. Neste conjunto de dados, temos os lados esquerdo e direito do intervalo de observação contendo o verdadeiro tempo de resposta e o sexo do paciente.

```
>dados("IR_diabetes")
>cabeça(IR_diabetes,3)
```

```
gênero esquerdo-direito
masculino 27 24 1
22mulheres 22 2
masculino 39 37 3
```

Ajustamos o modelo abaixo. Observe que isso pode ser demorado, como o modelo semiparamétrico é um tanto computacionalmente intenso e envolve `bs_amostras` bootstrapsamples do estimador.

```
> fit_ph<-ic_sp(cbind(esquerda,direita)~gênero,modelo='ph',
+               bs_samples=100,data=IR_diabetes)
> fit_po<-ic_sp(cbind(esquerda,direita)~gênero,modelo='po',
+               bs_samples=100,data=IR_diabetes)
```

O primeiro modelo padrão se adapta ao modelo Cox-PH, enquanto o segundo se adapta ao modelo proporcional, conforme controlado pelo modelo argumento. Podemos olhar para os resultados usando qualquer um dos resumo função, ou apenas olhando diretamente para os resultados (o que é exibido é o mesmo).

```
> ajuste_po
```

Modelo: ProportionalOdds

Estrutura de dependência assumida: Independência

Linha de base: chamada

semiparamétrica: ic\_sp(fórmula=cbind(esquerda,direita)~gênero,dados=IR\_diabetes,  
modelo="po",bs\_samples=100)

```
EstimateExp(Est)Std.Errorz-value p
2,8560,004286 masculino 0,4013 1,494 0,1405
```

finalllk=-1962.4

Iterações=25

Amostras de bootstrap= 100

```
> fit_ph
```

Modelo: CoxPH

Estrutura de dependência assumida: Independência

Linha de base: chamada

semiparamétrica: ic\_sp(fórmula=cbind(esquerda,direita)~gênero,dados=IR\_diabetes,  
modelo="ph",bs\_samples=100)

```
EstimateExp(Est)Std.Errorz-value p
0,07168 -1,9560,05042 masculino-0,1402 0,8692
```

finalllk=-1964,96

Iterações=36

Amostras Bootstrap= 100

Para modelos semiparamétricos, amostras de bootstrap são usadas para inferência os parâmetros de regressão. A razão para isso é que, até onde sabemos, o limiting distribution of the baseline distribution is currently not characterized.

Na verdade, ao nosso conhecimento, mesmo usando a bootstraper, há estimativas para o distribuição de linha de base não é válida. Porque os parâmetros de regressão não podem ser separados na função de verossimilhança, usando o inverso negativo do hessiano para os erros padrão de regressão não é geralmente válido. No entanto, foi demonstrado que usar o bootstrap para inferência sobre os parâmetros de regressão leva à validinaferência.

Podemos usar esses equipamentos para criar gráficos também. O enredo função irá plotar curvas de sobrevivência estimadas ou CDF para assuntos com o conjunto de covariáveis fornecidas


no novos dados argumento. Se novos dados

isleftequalto NULO ,a sobrevivência da linha de base

a função será plotada.

Abaixo está uma demonstração de como traçar os formulários de ajuste semiparamétricos e mulheres.

```
> newdata<-data.frame(gênero=c('masculino','feminino'))
> nomes de linhas(novos dados)<-c('homens','mulheres')
> plot(fit_po,novos dados)
```



### 2.3 Modelos Paramétricos

Modelos paramétricos Wecanfit em icenReg usando o ic\_par função. A sintaxe é essencialmente a mesma acima, exceto que o usuário precisa especificar dist ,a família paramétrica à qual pertence a distribuição de linha de base. O as escolhas atuais são "exponencial", "weibull" (padrão), "gama", "lnorm" (log-normal), "loglogístico" e "generalgamma" (gammadistribution generalizada). O usuário também deve selecionar modelo="ph" , "po" ,ou "ré" um tipo de modelo.

Não é necessário especificar bs\_amostras para modelos paramétricos, uma inferência é feita usando a normalidade assintótica dos estimadores. Ajustando-se a um modelo paramétrico modelo tipicamente mais rápido que o modelo semiparamétrico, mesmo se não for bootstrap amostras são coletadas para o modelo semiparamétrico. Isso ocorre porque o modelo totalmente paramétrico é de espaço dimensional inferior sem restrições.

Suponha que quiséssemos adaptar um modelo proporcional a ele Diabetes IR\_ dados com distribuição de gamadislinha de base. Isso poderia ser adequado por

```
>fit_po_gamma<-ic_par(cbind(esquerda,direita)~gênero,
+ dados=IR_diabetes,modelo="po",dist="gama")
```

Podemos examinar os coeficientes de regressão da mesma forma que com o modelo semiparamétrico.

```
>fit_po_gamma
```

Modelo: ProportionalOdds

Estrutura de dependência assumida: Independência

Linha de base: gama Call:ic\_par(fórmula=cbind(esquerda,direita)~gênero,dados=IR\_diabetes,

modelo="po",dist="gama")


|                 | Estimate | Exp(Est) | Std. Error | z-value | p        |
|-----------------|----------|----------|------------|---------|----------|
| forma_log       | 1,9980   | 7,377    | 0,05449    | 36,6700 | 0,000000 |
| escala_log      | 0,8248   | 2,281    | 0,05562    | 14,8300 | 0,000000 |
| homem do gênero | 0,3496   | 1,419    | 0,13550    | 2,5810  | 0,009865 |

finalllk=-2006.619

Iterações=4

Também podemos examinar os gráficos de sobrevivência/cdf da mesma maneira.

```
>plot(fit_po_gamma,newdata,lgdLocation="topright")
```



**2.4 Modelos Paramétricos Bayesianos** A opção por modelos bayesianos paramétricos também é permitida em `icenReg` com o `ic_bayes` função. Se o `latprior` for desejado, ele é exatamente idêntico a

`ic_par`.

```
> flatPrior_fit <- ic_bayes(cbind(esquerda, direita) ~ gênero,
+ dados = IR_diabetes, modelo = "po", dist = "gama")
```

Os métodos padrão funcionam da mesma maneira que outros `icenReg` se encaixa, embora a saída básica pareça bastante diferente.

```
> ajuste_anterior plano
```

Modelo: Bayesiano Proporcional Probabilidades

Dependência estrutura assumida: Independência

Linha de base: `gama` Call: `ic_bayes(fórmula = cbind(esquerda, direita) ~ gênero, dados = IR_diabetes,`

`modelo = "po", dist = "gama")`

Iterações = 2001:6996

Intervalo de afinamento = 5

Número de cadeias = 4

Tamanho da amostra por cadeia = 1000

1. Média empírica e desvio padrão para cada variável,  
mais erro padrão do meio:

|                        | Média   | SD      | Naive SE  | Time-series SE |                        |
|------------------------|---------|---------|-----------|----------------|------------------------|
| <code>log_shape</code> | 1,99550 | 0,05359 | 0,0008474 | 0,001399       | <code>log_scale</code> |
|                        | 0,82800 | 0,05433 | 0,0008590 | 0,001395       | <code>gênero</code>    |
| <code>masculino</code> | 0,34790 | 0,13489 | 0,0021328 | 0,003345       |                        |

2. Quantis for each variable:

|                        | 2,5%    | 75%     | 97,5%   | 25%     | 50%    |                        |
|------------------------|---------|---------|---------|---------|--------|------------------------|
| <code>log_shape</code> | 1,88786 | 1,95901 | 1,99492 | 0,3192  | 1,1005 | <code>log_scale</code> |
|                        | 0,72185 | 0,79080 | 0,82820 | 0,86440 | 0,9349 | <code>gênero</code>    |
| <code>masculino</code> | 0,08426 | 0,25590 | 0,34570 | 0,44010 | 0,6122 |                        |

3. Estimativas MAP:

| <code>log_shape</code> | <code>log_scale</code> | <code>gênero</code> | <code>male</code> |
|------------------------|------------------------|---------------------|-------------------|
| 2,0250                 | 0,3944                 | 0,7794              |                   |

Usuário que deseja acessar a amostra bruta e fazê-lo através do `$amostras campo`.

```
> head(flatPrior_fit$amostras)
```

| <code>log_shape</code> | <code>log_scale</code> | <code>gênero</code> | <code>male</code> |
|------------------------|------------------------|---------------------|-------------------|
| 2,02479                | 0,7980                 | 0,77939             | 18                |
| 0,3944                 | 293                    |                     |                   |

```
[2,] 1,9915990,8300576 0,2153600
[3,] 1,9739850,8451101 0,1870222
[4,] 2,0392080,8111638 0,2648244
[5,] 2,0736950,7470181 0,4964900
[6,] 1,9901020,8142439 0,4033938
```

Este objeto é uma matriz de amostras de todas as cadeias combinadas. Alternativamente, pode-se olhar para as amostras de cada cadeia individualmente através do `$mcmcLista` campo, com elemento correspondente a uma determinada cadeia. Observe isso `$mcmcLista` isa coda objeto da classe `lista mcmc`.

```
>#Accessingthefirstfewsamplesofthefirstchain
```

```
>cabeça(flatPrior_fit$mcmcList[[1]])
```

Saída MarkovChainMonteCarlo(MCMC):

Início=2001

Fim=2031

Intervalo de afinamento=5

log\_shape log\_scale gender male

```
[1,] 2,0247980,7793918 0,3944293
[2,] 1,9915990,8300576 0,2153600
[3,] 1,9739850,8451101 0,1870222
[4,] 2,0392080,8111638 0,2648244
[5,] 2,0736950,7470181 0,4964900
[6,] 1,9901020,8142439 0,4033938
[7,] 1,9442830,8672329 0,5043440
```

```
>#Accessingthefirstfewsamplesofthesecondchain
```

```
>cabeça(flatPrior_fit$mcmcList[[2]])
```

Saída MarkovChainMonteCarlo(MCMC):

Início=2001

Fim=2031

Intervalo de afinamento=5

log\_shape log\_scale gender male

```
[1,] 1,8896500,92143550,16743217
[2,] 2,1093490,69742560,40395324
[3,] 2,0309120,78561020,06858863
[4,] 1,9327050,88472340,27420770
[5,] 1,9828970,83973630,03247315
[6,] 2,0083480,82922450,08930453
[7,] 2,0388880,79297030,18199404
```


A densidade do logposterior, cada iteração, pode ser acessada através do `$logDensidadesPosteriores` campo. Observe que isso é realista, com cada item da lista sendo um vetor de cada cadeia.

```
>cabeça(flatPrior_fit$logPosteriorDensities[[1]])
```

```
[1]-2007.753-2007.119-2007.447-2008.976-2008.085-2007.596
```


Plotar chamadas é um padrão. Nota importante: os sólidos plotam o posterior estimativas medianas da curva de sobrevivência para um sujeito com determinadas covariáveis, não as estimativas do posteriormean!

```
> plot(flatPrior_fit,novos dados,  
+      main='Estimativas da Média Posterior')
```



Os gráficos diagnósticos MCMC podem ser gerados acessando o \$mcmcLista campo.

```
> plot(flatPrior_fit$mcmcList)
```



Como observado anteriormente, o comportamento padrão é usado muito antes. Se o visitante quiser usar um informativo com antecedência, ele pode fornecer o que for personalizado escrito com antecedência eles escolhem. Esta função deve assumir o vetor de valores correspondentes a todos os parâmetros do modelo (ou seja, primeiro parâmetros de linha de base e depois regressão parâmetros) e retornado o registro anterior, calculado até a constante aditiva.

Isto é ilustrado com um exemplo onde decidimos colocá-lo em uma posição precisa antes sobre o parâmetro de forma (ou seja, primeiro parâmetro de linha de base) e a regressão parâmetro e difuso anterior sobre o parâmetro da escala.

```
> logPriorFunction<-function(x){
ans<-0 +
ans<-ans+dnorm(x[1],sd=0,1,log=T) +
#Tightpriorabout1stparameter,log_shape + ans<-
ans+dnorm(x[2],sd=10,log=T) + #Diffusepriorabout2ndparameter,log_scale +
ans<-ans+dnorm(x[3],sd=0,1,log=T) + <TAG1>,parâmetro de regressão +
retorno(ans) +

+ } >informPrior_fit<-ic_bayes(cbind(esquerda,direita)~gênero,

+ dados=IR_diabetes,modelo="po",dist="gama",
+ logPriorFxn=logPriorFunction)
>#Fittingmodelwithprior.
>
>informPrior_fit
```

Modelo: BayesianoProporcionalOdds

Estrutura de dependência assumida: Independência

Linha de base: gama Call:ic\_bayes(fórmula=cbind(esquerda,direita)~gênero,dados=IR\_diabetes,

logPriorFxn=logPriorFunction,model="po",dist="gamma")

Iterações=2001:6996

Intervalo de afinamento=5

Número de cadeias=4

Tamanho da amostra por cadeia=1000

1.Média empírica e desvio padrão para cada variável,  
maiserro padrão do meio:

|           | Média    | SD        | NaiveSE   | Time-seriesSE |           |
|-----------|----------|-----------|-----------|---------------|-----------|
| log_shape | 1,445340 | 0,058140  | 0,0009193 | 0,001604      | log_scale |
| 1,370140  | 0,061230 | 0,0009681 | 0,001692  |               | gênero    |
| masculino | 0,098250 | 0,078810  | 0,0012461 | 0,001598      |           |

2.Quantisforeachvariable:

|          | 2,5%     | 75%      | 97,5%   | 25%   | 50% |             |
|----------|----------|----------|---------|-------|-----|-------------|
| 1,330931 | 1,406511 | 1,446191 | 1,48311 | 1,559 |     | log_shape   |
| 1,249841 | 1,329631 | 1,369461 | 1,41161 | 1,490 |     | log_scale   |
| 0,055720 | 0,044080 | 0,098240 | 1,5130  | 1,253 |     | gendermale- |


3.Estimativas MAP:

| log_shape | log_scale | gendermale |
|-----------|-----------|------------|
| 1,32300   | -0,01516  | 1,49000    |

Observe que o método posteriorm forma\_log é reduzido significativamente.

Comportamento padrão para ic\_bayes istouseanadaptiveMHblockupdater, começou a partir do estimativa MLE (não MAP) para ver o ponto de partida do cadeia e proposta inicial de covariância. A proposta de covariância é atualizada como mais amostras foram coletadas. Isso deve funcionar bem com probabilidades informativas e anteriores relativamente fracos. Por outro lado,pode ser bastante problemático probabilidades fracas e anteriores relativamente fortes. Nessas casos,o usuário pode preferir para desligar a inicialização do MLE. Isso pode ser feito com o controle bayesiano função.

```
>dados_fracos<-diabetes_IR[1:2,]  
>weakData_fit<-ic_bayes(cbind(esquerda,direita)~gênero,  
+ dados=dados_fracos,  
+ modelo="po",dist="gama",  
+ logPriorFxn=logPriorFunction,  
+ controles=bayesControls(useMLE_start=F))  
>plot(weakData_fit$mcmcList)
```



Observe que neste exemplo, vejamos evidências de que a cadeia não se misturou adequadamente, especialmente no que diz respeito ao `escala_log` parâmetro. Usando `bayesControles`, poderíamos aumentar ambas as amostras e queimar em direção a esse problema.

## 2.5 Extrair Estimativas e ICs

Também podemos extrair estimativas de sobrevivência e intervalos de confiança/confiáveis para um determinado conjunto de covariáveis que utilizam o `sobreviventesCIs`. `>#ExtractestimatesforinverseCDF`

```
>invCDF_est=survCIs(informPrior_fit,newdata,
+ p=seq(de=0,05, a=0,95, por=0,2))>#Extractestimatesfor*CDF*probabilidades em
valores dados
>CDF_est=survCIs(informPrior_fit,newdata,
+ q=seq(de=5,para=25,por=5))>invCDF_est
```

Chamada de modelo:

```
ic_bayes(fórmula=cbind(esquerda,direita)~gênero,dados=IR_diabetes,
logPriorFxn=logPriorFunction,model="po",dist="gamma")
```

Nível Credível=0,95

Nome da linha: machos

```
Percentilestimativa(média)estimativa(media) superior inferior
6,012255 5,4844126,525176 6,007985 0,05 [1,]
10,902751 10,90287510,32178411,466508 0,25 [2,]
14,631924 14,62929114,00160015,278505 0,45 [3,]
18,788092 18,77597918,08312219,564651 0,65 [4,]
```

```
[5,] 0,85                25.102949                25.07996724.07951826.214286
Nome da linha: fêmeas
      superior Percentileestimativa(média)estimativa(media) inferior
5,833583 5,2856516,352369 5,829669 0,05 [1,]
10,555256 9,91554311,166897 10,553974 0,25 [2,]
14,17457813.46639414.884354 14.178955 0,45 [3,]
18,25530417.43346619.133954 18.260706 0,65 [4,]
24,52258823,42370825,704973 24,533526 0,85 [5,] >CDF_est
```

Chamada de modelo:

```
ic_bayes(fórmula=cbind(esquerda,direita)~gênero,dados=IR_diabetes,
logPriorFxn=logPriorFunction,model="po",dist="gamma")
Nível Credível=0,95
Nome da linha: machos
      Estimativa de tempo (média)estimativa (mediana) inferior superior
[1,] 5 0,02819123 0,027840220,019906740,03821839
[2,] 10 0,20458708 0,204462290,177741730,23337367
[3,] 15 0,46950236 0,469737930,435779910,50259153
[4,] 20 0,69859319 0,698914880,667437880,72724340
[5,] 25 0,84768754 0,848235060,823170620,87034024 Nome da linha: fêmeas
```

```
inferior superior Estimativa de tempo (média) estimativa (mediana) Observe que a
saída do survC1 é usada para criar os gráficos [2,] 10 0,2210772
0,220790740,190515520,25462212 [3,] 15 0,4940004
0,494203620,455994190,53248912 [4,] 20 0,7187841
0,719080080,683835470,75092584 [5,] 25 0,8598682
0,860124630,834489050,88282417
```

icenReg se encaixa,então se alguém quisesse exportar o gráfico para ggplot ou traçar o posteriorman em vez do posteriormediano,por exemplo, alguém poderia fazer isso diretamente com sobreviventesCIs .

### 3 Inspeccionando o modelo de ajuste

#### 3.1Examinando a distribuição da linha de base

Embora o modelo semiparamétrico seja mais flexível e, portanto, mais robusto distribuições incomuns de linha de base,há muitas razões pelas quais elas podem decidir usar modelo aparamétrico em vez disso. Uma razão é que,como dito anteriormente,não somos ciente de qualquer teoria distribucional geral sobre a distribuição de linha de base, fora do caso univariado com casoIntervalo censurado dados. Mesmo neste caso,o estimador é altamente ineficiente,observando convergências de  $n^{1/3}$  em vez do padrão  $n^{1/2}$  .Por isso,não se pode fazer inferência sobre valores que exijam diretamente a distribuição da linha de base,como criar uma descoberta em intervalo para a mediana de assuntos com um determinado conjunto de covariáveis com o modelo semiparamétrico.


No entanto, mesmo que um modelo paramétrico seja usado para inferência final, este modelo semi-paramétrico ainda é útil para avaliar o ajuste do modelo. Isto é especialmente importante para dados censurados por intervalo, pois não temos a opção de examinar dados típicos

resíduos ou histogramas como fazíamos se o resultado não fosse censurado. `icenReg` tem a função `diag_linha` de base que traça várias escolhas de distribuições de linha de base paramétricas em relação à estimativa semiparamétrica. Se a distribuição paramétrica mostrar desvios sistemáticos do ajuste semiparamétrico, isso implica

a escolha da família paramétrica pode ser motivo para descrever o subjacente distribuição. Se houver desvios claros, esse modelo não deve ser confiável.

Usar `diag_linha` de base, você deve fornecer a ele um modelo ajustado, uma fórmula, dados e modelo. Então selecione as famílias paramétricas que você gostaria plotado contra a estimativa não paramétrica (padrão de tudo disponível). Como um exemplo, suponha que quiséssemos examinar os diferentes ajustes paramétricos para o `IR_diabetes` conjunto de dados. Isso poderia ser feito com

```
dists=c("exponencial", "weibull", +
>diag_baseline(cbind(esquerda, direita) ~ gênero, modelo = "
po", + dados = IR_diabetes, +
+ "loglogístico", "gama"),
+ lglLocation = "canto superior direito")
```



Alternativamente, usando os ajustes anteriores, podemos apenas ligar

```
>diag_baseline(fit_po, lglLocation = "topright",
+ dists = c("exponencial", "weibull",
+ "loglogístico", "gama")
+ )
```

O diagnóstico visual é sempre subjetivo, mas neste caso é definitivo: saiba que o exponencial não é apropriado e acreditamos na gama a linha de base é mais apropriada para o modelo de probabilidades proporcional (embora aqui esteja não é uma evidência esmagadora da melhor hepatite).

### 3.2 Examinando o efeito da covariância

Embora os modelos semiparamétricos não façam suposições sobre a família paramétrica da distribuição de linha de base, tanto totalmente paramétrica quanto semiparamétrica os modelos fazem suposições sobre a forma do efeito covariável, entrem no link [modelos de armas lineares generalizados em funcionamento](#).

Uma regra prática para identificar violações graves de riscos proporcionais é verifique se as curvas de Kaplan-Meier se cruzam; se o fazem, esse cruzamento não aparece puramente por acaso, a suposição de riscos proporcionais parece inapropriada.

Isto pode naturalmente estender-se ao caso de dados censurados por intervalo ou substituição as curvas Kaplan-Meier com o NPMLE. Além disso, este teste de informação pode ser generalizado para o modelo de probabilidades proporcional; a suposição de probabilidades proporcional implica também que as curvas de sobrevivência diferem apenas por um fator constante das probabilidades de sobrevivência não deve cruzar.



Outro método de avaliação envolve a transformação de suas estimativas de sobrevivência de modo que, se as suposições forem atendidas, a diferença na sobrevivência transformada será constante. Para o modelo de riscos proporcionais, esta é a transformação log-log complementar (ou seja,  $\text{registro}(\mathcal{RTAG}_{\infty T} \text{ registro}(s))$ ). Para o modelo de probabilidades proporcional, esta é a transformação logarítmica (ou seja,  $\text{registro}(s \leftarrow (1/\mathcal{RTAG}_{\infty T} s))$ ).

Plotar essas funções pode ser feito automaticamente em `icenReg` usando o `diag_covar` função. O fluxo básico é que a função assume o ajuste, divide os dados em uma covariância de interesse. Se for categórico, simplesmente se separa por categoria, se for numérica, tenta encontrar um ponto de interrupção para dividir uniformemente dados. Então, para cada subconjunto dos dados, ele se ajusta ao parâmetro semi correspondente modelo e plotagem da transformação da distribuição de linha de base.

Para demonstrar, suponha que quiséssemos avaliar se o modelo de probabilidades proporcional de Cox-PH era mais apropriado para o IR\_diabetes. Isso poderia ser feito por

```
>diag_covar(fit_po,lgdLocation="topright",
+ main="VerificandoProporcionaisProbabilidades")
>diag_covar(fit_ph,lgdLocation="topright",
+ main="Verificando Riscos Proporcionais")
```

Nós gostamos especialmente de gênero, as probabilidades proporcionais parecem um pouco mais apropriado (a diferença entre os valores transformados parece mais constante). Isto concorda com o facto de a probabilidade ser aproximadamente 2,5 maior para o modelo de probabilidades proporcional que Cox-PH.



## 4Apêndice

### 4.1 Bootstrapping Paralelo

O bootstrapping pode ser muito intensivo em termos computacionais. Felizmente, também é embarçosamente paralelo. Como tal, o `icenRegis` escreve para trabalhar perfeitamente com `doParallel`

```
>biblioteca(doParallel)
>meuCluster<-makeCluster(4)           #uses4cores
```

```
>registerDoParallel(meuCluster)
>fit<-ic_sp(cbind(esquerda,direita)~gênero,
+ dados=IR_diabetes,modelo="po",
+ bs_samples=50,useMCores=TRUE)
>stopCluster(meuCluster)
```